


Tugas

Link:

<https://drive.google.com/drive/folders/1pMRvPhRVpzW9UkfcMJlaBXaDPdRE4gqw?usp=sharing>

1. Klasifikasi dengan 1 metode untuk titanic dengan menggunakan Rapid Miner dan Python. Bandingkan hasilnya. Tunjukkan performancenya



Dataset ini berisi informasi dari 1309 penumpang Titanic, dengan beberapa fitur utama sebagai berikut:

- **Passenger Class:** Kelas tiket penumpang (First, Second, Third).
- **Sex:** Jenis kelamin penumpang.
- **Age:** Usia penumpang.
- **No of Siblings or Spouses on Board:** Jumlah saudara atau pasangan di kapal.
- **No of Parents or Children on Board:** Jumlah orang tua atau anak di kapal.
- **Ticket Number:** Nomor tiket.
- **Passenger Fare:** Biaya tiket yang dibayar.
- **Cabin:** Nomor kabin.
- **Port of Embarkation:** Pelabuhan tempat naik kapal.
- **Survived:** Status kelangsungan hidup (Yes = selamat, No = tidak selamat).

Hasil RapidMiner

accuracy: 81.30%

	true Yes	true No	class precision
pred. Yes	62	11	84.93%
pred. No	38	151	79.89%
class recall	62.00%	93.21%	

Hasil Python

- **Accuracy:**

```
Accuracy: 82.44%  
Confusion Matrix:  
[[141  21]  
 [ 25  75]]
```

- **Classification Report:**

```
              precision    recall  f1-score   support  
  
    0           0.85        0.87        0.86         162  
    1           0.78        0.75        0.77         100  
  
 accuracy          0.82          0.82          0.82         262  
 macro avg         0.82          0.81          0.81         262  
weighted avg         0.82          0.82          0.82         262
```


Preprocessing

- Model **Logistic Regression** menghasilkan akurasi **81.30% di RapidMiner** dan **82.44% di Python**.
- Python menunjukkan performa yang sedikit lebih baik dalam hal akurasi dan keseimbangan antara precision dan recall.
- **Confusion Matrix** menunjukkan bahwa model memiliki kecenderungan lebih baik dalam mengklasifikasikan penumpang yang tidak selamat dibandingkan yang selamat.
- **Perbedaan hasil bisa disebabkan oleh perbedaan implementasi preprocessing dan parameter default yang digunakan dalam RapidMiner dan Python.**

- Klasifikasi dengan 1 metode untuk iris dengan menggunakan Rapid Miner dan Python. Bandingkan hasilnya. Tunjukkan performancinya. Pahami multi class dan binary

Binary Classification: Klasifikasi dengan **hanya dua kategori** (contoh: "Malignant" vs "Benign" pada dataset *Breast Cancer*).

Multi-class Classification: Klasifikasi dengan **lebih dari dua kategori** (contoh: "Iris-setosa", "Iris-versicolor", "Iris-virginica" pada dataset *Iris*).



- Jumlah data:** 150 sampel
- Fitur yang digunakan:** Sepal length (a1), Sepal width (a2), Petal length (a3), Petal width (a4)
- Target class:**
 - 0: Iris-setosa
 - 1: Iris-versicolor
 - 2: Iris-virginica

Hasil RapidMiner

accuracy: 96.00% +/- 4.66% (micro average: 96.00%)

	true Iris-setosa	true Iris-versicolor	true Iris-virginica	class precision
pred. Iris-setosa	50	0	0	100.00%
pred. Iris-versicolor	0	47	3	94.00%
pred. Iris-virginica	0	3	47	94.00%
class recall	100.00%	94.00%	94.00%	

Hasil Python

- **Single Train-Test Split**

Accuracy: 100.00%


	precision	recall	f1-score	support
Iris-setosa	1.00	1.00	1.00	10
Iris-versicolor	1.00	1.00	1.00	9
Iris-virginica	1.00	1.00	1.00	11
accuracy			1.00	30
macro avg	1.00	1.00	1.00	30
weighted avg	1.00	1.00	1.00	30

- **Cross Validation**

```
# 1 Evaluasi dengan Cross-Validation
scores = cross_val_score(rf_model, X, y, cv=5) # 5-fold cross-validation
print(f'Cross-Validation Accuracy: {scores.mean() * 100:.2f}% ± {scores.std() * 100:.2f}%')
```

↩ Cross-Validation Accuracy: 96.67% ± 2.11%

Cek Feature Importance




- Fitur a3 dan a4 memiliki pengaruh paling besar dalam klasifikasi, sementara a2 hampir tidak berkontribusi.

3. <https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>.

Lakukan feature selection dengan PCA dengan 1 metode klasifikasi. Rapid Miner dan program

- **Jumlah sampel:** 569
- **Fitur yang digunakan:** 30 fitur numerik seperti radius mean, texture mean, perimeter mean, dll.
- **Target class:**
 - 0: Benign (Jinak)
 - 1: Malignant (Ganas)



Hasil RapidMiner

accuracy: 96.67% +/- 3.92% (micro average: 96.66%)

	true M	true B	class precision
pred. M	197	4	98.01%
pred. B	15	353	95.92%
class recall	92.92%	98.88%	

Hasil Python

- **Single Train-Test Split**

Test Set Accuracy: 95.61%

Classification Report:

	precision	recall	f1-score	support
0	0.96	0.97	0.97	71
1	0.95	0.93	0.94	43
accuracy			0.96	114
macro avg	0.96	0.95	0.95	114
weighted avg	0.96	0.96	0.96	114

- **Cross Validation**

```
knn = KNeighborsClassifier(n_neighbors=5)  
cv_scores = cross_val_score(knn, X_pca, y, cv=5)
```

[+ Code](#)[+ Text](#)

```
print(f"Cross-Validation Accuracy: {np.mean(cv_scores) * 100:.2f}% ± {np.std(cv_scores) * 100:.2f}%")
```

Cross-Validation Accuracy: 96.13% ± 1.32%

Analisis Hasil:

1. Model K-NN mendapatkan akurasi sebesar 96.13% pada **Cross-Validation**.
2. Dengan data uji, akurasi model adalah 95.61%.
3. PCA membantu mengurangi dimensi data, tetapi tetap mempertahankan informasi yang cukup untuk klasifikasi.
4. Model K-NN bekerja cukup baik dalam membedakan antara kanker **Malignant** dan **Benign**.